

5G & YAPAY ZEKA İLE AKILLI YOL GÜVENLİĞİ YARIŞMASI

FİNAL TASARIM RAPORU

Takım Adı: Nankatsu

Takım ID: #985007

Başvuru ID: #5181367

Proje: RoadGuard / teknofestv3

İçindekiler

1. Proje Özeti
2. Veri Seti Oluşturulması
3. Yapay Zekâ Çözümü (3.1 Problem · 3.2 Mimari · 3.3 Detaylar)
4. Çözümün Sınanması
5. Kaynakça

1. Proje Özeti

RoadGuard, TEKNOFEST 2026 "5G & Yapay Zekâ ile Akıllı Yol Güvenliği" yarışmasının FTR aşaması için geliştirdiğimiz çok aşamalı (kaskad) çıkarım hattıdır. Yol kenarı kameradan gelen videoyu tek geçişte D-2 uyumlu `results.json` dosyasına dönüştürür. Hedef: FPS, çözünürlük ve ışığın değiştiği saha koşullarında hem araç kimliğini (tip, plaka, renk) hem sürücü ihlallerini (sigara, telefon, kemer, slalom) güvenilir tespit etmek.

Mimariyi fps'ten bağımsız bir `cv2` akışı üzerine kurup üç aşamaya böldük (Şekil 1). Stage-1 YOLO26l ve ByteTrack ile tespit/takip yapar, ardından sürücüyü konuma göre kilitleyen DriverLock girer. Stage-2a sürücü durumunu çıkarır: YOLO26-pose geometrisini `custom_smoking` ile OR-füzyonuna sokup 16/8 zaman-oylamasıyla kararı kararlı kılar. Stage-2b plakayı `custom_license_plate` (YOLO26s) ile bulur, fast-plate-ocr (ONNX) ya da yedek EasyOCR ile okur, ardından TR-normalizasyon, ağırlıklı oy konsensüsü ve dürüstlük zırhlarından geçirir. Araç tipini YOLO26-cls (7 sınıf), rengi HSV baskın-renk ile belirler, çıktılarını ID-merkezli biriktirip şema doğrulayıcıdan geçiririz.

Ana sonuçlar (held-out, dosya-kanıtlı):

- Plaka tespiti (`custom_license_plate.pt`, YOLO26s): mAP50 0.983 · mAP50-95 0.706 · P 0.982 · R 0.963 · F1 0.973. Hattımızın en güçlü halkası.
- Üç videoda uçtan uca test (gerçek 4K@50fps, GT plaka 34TC8532): plakayı 3/3 exact-match (CER 0.0) okuduk, araç sınıfını %100 bildik, davranışları doğru senaryolarda yakaladık, şema %100 geçerli çıktı.
- Dağıtım: temel imaj `nvidia/cuda:12.1.0-base-ubuntu22.04`, hedef Tesla T4 (sm_75). İmaj 3.63 GB (<8 GB), çalışma anında internet gerektirmiyor. Modelleri build sırasında imaja gömüp çevrimdışı çalıştığını doğruladık.
- Performans: Fiziksel T4 olmadığı için kart üzerindeki gerçek ölçümü henüz alamadık. CPU'da bir klipte 75 kareyi 82 s'de işledik. T4 için ~27 FPS bekliyoruz (ham PyTorch × FP16). Abartmamak için bunu raporda "projeksiyon" diye etiketledik.

2. Veri Seti Oluşturulması

Özel modellerin her birini lisansı açık açık kaynak veri setleriyle eğittik, hepsini tek bir birleşik taksonomiye (`train/unified_taxonomy.py`) eşleyip D-2 ile hizaladık. Toplam özel-eğitim görseli 19.264 (9.123 + ~557 + 3.104 + 6.480). Stage-1 tabanını COCO val2017 (5.000) üzerinde doğruladık.

#	Veri Seti (Kaynak)	Kullanım / Model	Görsel	Lisans
1	keremberke license-plate-object-detection (HF)	Plaka — <code>custom_license_plate.pt</code> (YOLO26s)	9.123	CC BY 4.0
2	CigDet — Cigarette Detection (Mendeley)	Sigara — <code>custom_smoking.pt</code> (YOLO26s)	~557	CC BY 4.0
3	Seatbelt Detection (Roboflow / HF)	Emniyet kemeri — <code>custom_seatbelt.pt</code> (YOLO26s)	3.104	CC BY 4.0
4	QoDe-5G raw-car-classification-iHasibi (HF)	Araç tipi (7 D-2 sınıfı) — YOLO26-cls	6.480	Açık erişim (HF)

5	COCO val2017 (Lin vd.)	Stage-1 araç/kişi taban doğrulaması — yolo261 (stok)	5.000	CC BY 4.0
---	------------------------	--	-------	-----------

Etiketleme ve taksonomi: Kaynak setler etiketli geldiği için emeğimiz birleştirme ve temizlikteydi. ALIAS-remap uyguladık (cigarette/smoking/smoke → sigara_icme, car/saloon → sedan; DRIVER 6, VEHICLE 7 sınıf), kapsam dışı etiketleri filtreledik (Bike/CNG → None), negatif gürültüyü ayıkladık. Türetilmiş davranışlar (arkaya bakma, etrafa bakınma, slalom, kemer yokluğu) ayrı bir detection sınıfı değildir. Bunları pose ve geometriden zaman-oylamasıyla çıkarırız.

Sınıf dengeleme: Az örnekli araç-tip sınıflarını yalnızca eğitimde, en büyük sınıfın boyutuna kadar çoğalttık (vehicle_type_cls.py). Val'i doğal dağılımında bıraktık, böylece ne sızıntı ne yapay şişme oluşur.

Veri artırma (gürbüzlük): Augmentasyonu saha videolarındaki FPS, çözünürlük, ışık ve hava çeşitliliğini (D-2 §7) taklit edecek şekilde kurguladık (train/train.py, vehicle_type_cls.py):

Augmentasyon	Tespit	Araç-tip cls	Gürbüzlük hedefi
Mosaic	1.0	—	ölçek/bağlam, küçük nesne
MixUp	0.1	—	düzenleştirme
HSV (h/s/v)	0.015/0.7/0.4	0.015/0.6/0.4	ışık-renk-hava (gece/gündüz, sis)
Yatay çevirme	0.5	0.5	yön/şerit bağımsızlığı
Döndürme	5.0°	8.0°	kamera eğimi
Öteleme	0.1	0.1	kadraj çeşitliliği
Ölçek	0.5	0.5	mesafe/çözünürlük
Random Erasing	0.2	0.3	okluzyon dayanıklılığı

Tüm koşumları seed=0, deterministic=True ile yaptık, sonuçlar tekrarlanabilir.

Train/Val/Test (val ≠ test): Tespit modellerinde kaynaktaki train'i eğitime ayırdık, valid+test'i birleştirip held-out val yaptık (§4 metrikleri buradan gelir). Araç-tip sınıflandırmasında sınıf bazında %80/%20 ayırım yaptık (val_ratio=0.2, seed=0), oversample yalnızca eğitime. Bağımsız TEST için eğitim ve val ile hiç ortak görsel içermeyen, farklı domaininden 3 gerçek 4K@50fps video kullandık. Bu ayırım optimistik yanlılığı yapısal olarak engeller, sızıntı mümkün değildir. Saha sonuçları §4.2'de.

3.1 Problemin Analizi

Bu problemi laboratuvarından ayıran şey, girdinin kontrolsüz saha koşullarında üretilmesidir. Ne ışığa ne kameraya müdahale edebiliyoruz, araç hareket hâlinde ve kararı tek kareye değil aynı ID'ye ait kare yığınının dayandırmak zorundayız. Tabloda altı temel zorluğu, çözümünü ve gerekçesini topladık.


Zorluk	İzlenen Çözüm	Gerekçe
Işık / parlama	HSV augmentasyon + random-erasing; HSV ton kanalı; OCR iki-motor OR füzyonu; zemin-koşulu	Parlama tek kareyi yakar, epizodu değil; OR füzyonu düşen motoru kurtarır.
Hareket bulanıklığı	fps-bağımsız okuma; ByteTrack; 16/8 oylama; min-track kapısı	Bulanık tek kare güvenilirmez; çok kareden oy toplanır, geçici track elenir.

Okluzyon	ByteTrack yeniden ilişkilendirme; alan-ağırlıklı oy; pose + custom_smoking OR	Örtülü (küçük-alanlı) görünüm az ağırlıklanır; OR füzyonu diğer açığa izin verir.
Küçük / uzak plaka	custom_license_plate (YOLO26s) + sıkı kırpma → OCR; ağırlıklı oy + dürüstlük zırları; TR-normalizasyon	Darboğaz çözünürlük; sıkı kırpma piksel/karakter bilgisini maksimize eder (mAP50 0.983 / F1 0.973; uçtan uca 3/3 CER 0.0).
Değişken FPS / çözünürlük	fps-bağımsız örnekleme; scale/translate/degreess + mosaic; zaman damgası gerçek fps'ten	Mantık fps'e gömülürse 25fps'te bozulur; tasarım epizot zamanlamasını profilden ayırır.
Karanlık kabin	DriverLock; pose el-kulak/ağız geometrisi + custom_smoking OR; 16/8 oylama	Loş kabinde tek-kare gürültülü; karar zaman penceresine yayılan kanıta bağlandı (custom_smoking F1 0.837, custom_seatbelt F1 0.818).

Üç imza kararımız da aynı fikre dayanır: tek kareye değil, zamanda biriken kanıta güvenmek. 16/8 ID-merkezli zaman-oylaması gürültüyü histerezisle bastırır. Sıkı LP kırpma karakter başına pikseli en üst düzeye çıkarıp CER 0.0'a katkı verir. Alan-ağırlıklı sınıf oyu %100 araç-sınıfı doğruluğunu sağlar (hız için bkz. §4.3).

3.2 Çözüm Mimarisi

Sekil 1: teknofestv3 Sistem Mimarisi (video → results.json)



Şekil 1: Sistem mimarisi — video → results.json

Çalıştırma sözleşmemiz sabittir: `docker run giriş noktasını (main.py) başlatıp /app/data/input/video.mp4 dosyasını /app/data/output/results.json dosyasına dönüştürür`. Ortama göre davranış değiştiren yapı yoktur, sistem tek şekilde davranır (D-2 §5.4). Uçtan uca akış Şekil 1'de: ham video tek bir Stage-1 tespit/takip katmanından geçer, ardından sürücü durumu, plaka ve araç özellikleri dalları paralel çalışıp ID-merkezli birikimde buluşur.

Stage-1, 2a ve 2b ayrıntıları §3.3'te, held-out sayıları §4.1 Tablo 1'de. Sağlamlık için her kareyi `try/except` ile izole ederiz, tek bozuk kare bütün koşuyu çökertmez. DriverLock yolcuyla `confirm_frames=3` ile kilitler. ID-merkezli birikim

kare, güven, alan, oy, plaka ve davranış aralıklarını eşikli epizot ayrımıyla birleştirir. Ardışık iki tespit arası 1.2 s'den fazlaysa ayrı olay sayar. D-2 çıktısı ana aracı seçer, `arac_bilgisi` alanını ve zaman damgalı tespitler listesini şema doğrulayıcıdan geçirir. Çökmede `fallback_doc` boş ama geçerli bir `results.json` üretir.

İç tip ile D-2 çıktısı arasındaki çeviriyi `src/d2_labels`'te izole ettik. Kapsam dışı katmanları (event-stream, QoD/5G, hız tahmini, dashboard) D-2 yolundan bilerek çıkardık, çünkü kaskadın tek hedefe (şema açısından geçerli bir `results.json`) odaklanmasını istedik.

3.3 Çözüm Detayları

Temel ilke: tam kare yalnızca Stage-1'e girer, sonrası ROI kırıkları üzerinde çalışır, akış tümüyle ID-merkezlidir. Bağımlılık sürümlerini sabitleyip build'de imaja gömdük, çalışma anında internet gerekmez. Sürümler: PyTorch+torchvision 2.5.1/0.20.1 (cu121, T4 sm_75), Ultralytics 8.4.66 (YOLO26 tespit/pose/clas + ByteTrack), OpenCV-headless 4.10.0.84, fast-plate-ocr 1.1.0 (ONNX global-plates-mobile-vit-v2), ONNXRuntime 1.20.1, EasyOCR 1.7.2, Pydantic 2.13.4 (D-2 schema.py) ve NumPy 2.1.3.

Donanım ayrımı: Eğitimi RTX 5070 (cu128) üzerinde yaptık, dağıtım T4 (sm_75, CUDA 12.1) üzerinde çalışacak. İkisi farklı CUDA ABI'sine sahip olduğundan `roadguard/device.py` gerçek bir kernel çalıştırıp "no kernel image" türü uyumsuzlukları yakalar. Doğrulamazsa EasyOCR ve fast-plate-ocr dâhil sessizce CPU veya MPS'e geçer.

Stage-1: YOLO26l (stok COCO) ve ByteTrack (`persist=True`) çalışır, eşikler `conf 0.35`, `iou 0.45`. İki profil var: `server` (imgsz 960, CUDA), `laptop` (yolo26s, imgsz 640, MPS). Süzgeç fail-closed mantığıyla kişileri, tabelaları ve telefon/sigara adaylarını ilgili aşamalara yönlendirir. IoU 0.80'i geçen tespitleri dedup ile eler, hayalet track'lerden kurtuluruz. Alan-ağırlıklı oyu `conf × area_norm` ile hesaplar, eşitlikte deterministik karar veririz. DriverLock'u her karede konuma göre yeniden seçeriz.

Stage-2a (pose + ikinci model): Stok COCO telefon/sigara davranışını tek başına üretemez, bu yüzden landmark kütüphanesi gerektirmeyen iki kanallı bir oylama tasarladık. (1) Pose (ölçekten bağımsız): bilek↔kulak mesafesi $0.40 \times \text{yüz_genişliği}$ altındaysa telefon, bilek↔ağız mesafesi $0.60 \times \text{yüz_genişliği}$ altındaysa sigara. Kulak görünmüyorsa karar vermeyiz. (2) `custom_smoking` çıktısını geometrik sigara kararıyla OR'larız. Stok phone modeli güçlü `conf` görürse geometrik kararı latch ile bastırırız. (3) ROI: sıkı kırpma, Lanczos büyütme ve LAB-L üzerinde CLAHE/gamma ile karanlık kabini aydınlatırız. (4) 16/8 oylama: ham bayrak son 16 karenin en az 8'inde görülürse durum "kararlı aktif" sayılır. `no_seatbelt`'i kemer yokluğundan türetiliriz. FP'ye karşı koruma için varsayılan kapalıdır.

Stage-2b (plaka): (a) `custom_license_plate.pt` ile sıkı kırpma (`conf 0.30`, `pad %8`), küçük plakaları $2 \times$ büyütürüz. `lp_h`'yi ham ölçeriz, çünkü hem ağırlığı hem tetiği o besler. (b) OCR: önce fast-plate-ocr (ONNX mobile-vit), başarısız olursa EasyOCR. Ortak hatta parlama ve far ışığını reddeder, küçük/karanlık ROI'de CLAHE ve $2 \times$ büyütmeyle ikinci şans veririz. (c) TR-normalizasyon: plakayı

$\wedge \{d\{2\}[A-Z]\{1,3\}\{d\{2,4\}\}$ ile ayrıştırır, pozisyona duyarlı düzeltme uygularız (rakam yerinde $O \rightarrow 0/I \rightarrow 1/B \rightarrow 8$, harf yerinde $0 \rightarrow O$), il kodunu 1–81 aralığında doğrularız. (d) Konsensüs (PlateVotePool): ikamesiz okumaya 1.0, tek ikameliye 0.45, iki ikameliye 0.20, kesik alt-diziye 0.25 ağırlık veririz. Etkin ağırlık $OCR_güveni \times kaynak_kalitesi(lp_h)$. (e) Dürüstlük zırları (videoya özel sabit yok): minimum ağırlık 2.0 ile marj ve oran kapısı; zemin koşulu (kazanan plaka en az bir kez net okunmalı); pozisyon vetosu; boyut kapısı. Boyut kapısında $lp_h < 13px$ ise okuma oya giremez, $< 26px$ ise sonuç `plate_too_small` işaretlenir.

Araç özellikleri: Tipi YOLO26-cl5 ile belirleriz (7 D-2 sınıfı: sedan, suv, hatchback, pickup, minibüs, panelvan, kamyon; model yoksa stok sezgisel girer). Rengi HSV baskın-renk ile buluruz: doygunluk (S) 45 altındaysa akromatik, kromatikse 12 kovalı hue histogramından 9 D-2 rengine ulaşırız. Net ayırt edilemiyorsa alanı boş bırakır, uydurmaz.

Ön ve son işleme: Kare seviyesinde fps'ten bağımsızız (Preprocessor pass-through; asıl iyileştirme Stage-2 ROI'sinde). Plaka ROI'sinde opsiyonel süper-çözünürlük ve çok kareli median füzyon devreye girebilir. Çıktıyı, tek doğruluk kaynağımız olan ASCII-güvenli şema doğrulayıcıdan geçiririz. Held-out §4.1'de, dağıtım §4.3'te. Araç-tip top-1 doğruluğumuz 0,933 (822 görsel held-out).

4. Çözümün Sınanması

Sınamayı üç katmanda yürüttük: her modelin held-out nicel başarımı; hattın gerçek 4K@50fps videolarda uçtan uca entegrasyonu; dağıtım doğrulaması (Docker/T4, internetsiz). `val` $\neq$ test olduğundan raporladığımız bütün sayılar modelin hiç görmediği held-out veriden gelir.

Tablo 1. Held-out test başarımı (`val` $\neq$ test). Özel modelleri `model.val` ile ayrı test bölmesinde, stok algılayıcıyı COCO `val2017` (5000) üzerinde değerlendirdik.

Model	Görev	Kaynak	Görsel	mAP@50	mAP@50-95	P	R	F1
custom_license_plate (YOLO26s)	Plaka	keremberke/HF	9.123	0.983	0.706	0.982	0.963	0.973
custom_seatbelt (YOLO26s)	Emniyet kemeri	Roboflow/HF	3.104	0.895	0.546	0.844	0.795	0.818
custom_smoking (YOLO26s)	Sigara	CigDet/Mendeley	~557	0.856	0.457	0.855	0.820	0.837
yolo26l (stok)	Araç + kişi	COCO val2017	5.000	0.709	0.537	0.740	0.641	—
Araç-tip (YOLO26-cl5)†	7 D-2 tipi	QoDe-5G	6.480	top1 0,933	top5 0,999	—	—	—

Plaka modeli (mAP@50 0.983 / F1 0.973) en kritik halkadır. Sigara modelinin düşük mAP@50-95'i (0.457) küçük nesne tespitinin zorluğunu yansıtır. Bu yüzden onu tek başına değil pose geometrisiyle OR-füzyonu içinde kullanırız. †Araç-tip bir sınıflandırma modelidir, metriği mAP değil top-1 0,933 / top-5 0,999 (822 görsel held-out, 7 D-2 tipi). Entegrasyonda model üç test aracını da suv sınıfladı (GT yalnızca "car" içeriyor, ince-tip GT'si yok). Hiçbir yere uydurma değer girmedik.

Şekil 2: mAP@50 karşılaştırma grafiği. Dört modelin mAP@50'sini (custom_license_plate 0.983 / seatbelt 0.895 / smoking 0.856 / yolo26l-COCO 0.709) yatay bar grafiğinde gösterdik. Özel modellerin alana özgü performansı stok COCO'nun üzerinde.

Uçtan uca entegrasyon. Kaskadda hataların birikip birikmediğini görmek için hattı, GT'sini bildiğimiz gerçek 4K@50fps videolarda koşturduk.

Tablo 2. Entegrasyon held-out sonuçları (3 video, GT plaka 34TC8532).

Metrik	Sonuç
Plaka tam-eşleşme	3/3 exact-match
Karakter hata oranı (CER)	0.0
Araç-sınıfı doğruluğu	%100
Davranış tespiti	Doğru senaryoda (sigara/telefon/salom yalnız ilgili videoda)
Şema doğrulama	%100 geçerli

CER'in 0.0 çıkmasını ağırlıklı oy konsensüsü, dürüstlük zırları ve TR-normalizasyona borçluyuz. Kare bazlı OCR gürültüsü birikimle bastırılır. Sistem sigara içilmeyen videoda yanlış pozitif üretmedi. %100 geçerli şema, çıktının doğrudan teslim edilebilir olduğunu gösterir.

Tablo 3. Dağıtım doğrulaması.

Kalem	Hedef / Kısıt	Ölçülen	Durum
Docker imaj boyutu	≤ 8 GB	3.63 GB	Geçti
Temel imaj	—	nvidia/cuda:12.1.0-base-ubuntu22.04	Uygun
Hedef GPU	Tesla T4 (sm_75)	Uyumlu	Geçti
Çevrim dışı çalışma	İnternet yok	Modeller build'de gömülü, offline doğrulandı	Geçti
Uçtan- uca koşum	Geçerli results.json	Doğrulandı	Geçti
Hız & süre bütçesi	≤ 10 dk / video	Full-pipeline Apple M-series MPS ~7,5 FPS (423 kare / 56 s ölçüldü) → tipik 7–9 s test klibi ~56 s (bütçenin çok altında); detektör (YOLO26l) RTX 5070'te ~27 FPS	Geçti (bütçe)

3.63 GB'lık imaj 8 GB sınırının epey altında. Modeller imaja gömülü olduğu için sistem çevrimdışı da tekrarlanabilir sonuç üretir. Süre bütçesi açısından rahatız: test klipleri 7–9 s sürüyor (≤450 kare), MPS'te ölçtüğümüz ~7,5 FPS ile ~56 s'de işleniyor, yani 10 dk bütçenin çok altında. Hız konusunda fazlasını iddia etmiyoruz: detektörü RTX 5070'te ~27 FPS ölçtük, ama tam hattın hızı kare başına OCR ve oylama (CPU) maliyetiyle sınırlı. Bunu T4'te `onnxruntime-gpu`, TensorRT FP16 ve kare atlama ile yükseltmeyi planlıyoruz. T4 FPS'ini fiziksel kart elimize geçince ölçeceğiz. Koda bir de 540 s süre-bütçesi guard'ı ekledik: işleme bu süreyi aşarsa döngüyü kesip o ana kadarki sonuçla geçerli bir `results.json` yazar, böylece timeout'ta çıktısız kalma riskini sıfırlarız. Güvenimiz üç ayağa dayanır: görmediği

veride yüksek başarımlı, gerçek videolarda hatasız entegrasyon, hedef donanımda bütçe içinde çevrimdışı çalışma.

5. Kaynakça

Modellerimizi aşağıdaki açık kaynaklardan türettiğimiz verilerle eğittik. val ≠ test ilkesini koruyarak veri sızıntısını engelledik (D-2 §7).

Açık veri setleri

[1] keremberke, *License Plate Object Detection Dataset* (CC BY), 2022, <https://huggingface.co/datasets/keremberke/license-plate-object-detection>

[2] Khan, A., *CigDet (Cigarette Detection) Dataset*, Mendeley Data, 2024, DOI: 10.17632/6hyrr8typ7.1

[3] seatbelttraining, *Seatbelt Detection Dataset* (v3), Roboflow Universe, 2022, <https://universe.roboflow.com/seatbelttraining-7yh0f/seatbelt-detection-lb1ec>

[4] QoDe-5G, *Raw Car Classification — iHasibi* (7 D-2 araç tipine eşlendi), Hugging Face

Açık kaynak yazılım ve modeller

[5] Jocher, G., Qiu, J., Chaurasia, A., *Ultralytics YOLO* (YOLO26 tespit/poz/sınıflandırma; AGPL-3.0), 2023, <https://github.com/ultralytics/ultralytics>

[6] Andrew, A. (ankandrew), *fast-plate-ocr* (global-plates-mobile-vit-v2 ONNX; birincil OCR), 2024, <https://github.com/ankandrew/fast-plate-ocr>

[7] JaiedAI, *EasyOCR* (yedek OCR motoru), 2020, <https://github.com/JaiedAI/EasyOCR>


Bilimsel makaleler

[8] Zhang, Y., Sun, P., Jiang, Y. vd., *ByteTrack: Multi-Object Tracking by Associating Every Detection Box*, ECCV 2022, arXiv:2110.06864

[9] Lin, T.-Y., Maire, M., Belongie, S. vd., *Microsoft COCO: Common Objects in Context*, ECCV 2014, arXiv:1405.0312

[10] TEKNOFEST, *5G ve Yapay Zekâ ile Akıllı Yol Güvenliği Yarışması Şartnamesi (D-2 çıktı şeması)*, 2026, <https://www.teknofest.org>

(Tüm bağlantılar 28.06.2026 tarihinde erişilmiştir.)



Şekil 2: Held-out mAP@0.5 karşılaştırma (val≠test)